

**Sistem Algoritma Rekomendasi Game pada *Website*
Berbasis Ontologi dan SWRL (*Semantic Web Rule
Language*)**

Tugas Akhir

**diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana dari
Program Studi Rekayasa Perangkat Lunak Fakultas Informatika**

Oleh:

1302210126

Yosua William Pallunan



**Program Studi Sarjana Rekayasa Perangkat Lunak
Fakultas Informatika
Universitas Telkom
Bandung
2025**

LEMBAR PERSETUJUAN

**Sistem Pemberi Rekomendasi Produk Game pada *Website* Berbasis Ontologi
dan SWRL (*Semantic Web Rule Language*)**

***Game Product Recommendation System on Website Based on Ontology and
SWRL (Semantic Web Rule Language)***

1302210126

Yosua William Pallunan

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana Rekayasa Perangkat Lunak

Fakultas Informatika

Universitas Telkom

Bandung, xx xx 2025

Disetujui Oleh,

Pembimbing I

Pembimbing II

Dade Nurjanah, S.T., M.T., P.h.D

Selly Meliana, M.Kom

97730005

23780002

Ketua Program Studi

Sarjana Rekayasa Perangkat Lunak

Jati Hiliamsyah Husen, S.T., M.Eng., Ph.D.

20920040

LEMBAR ORISINALITAS

Dengan ini saya, **nama**, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul “**Sistem Algoritma Rekomendasi Game pada Website Berbasis Ontologi dan SWRL (*Semantic Web Rule Language*)**” berserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, xx xx 2025



Yosua William Pallunan

1302210129

ABSTRAK

Penelitian ini bertujuan untuk merancang dan mengimplementasikan sistem rekomendasi game berbasis web yang memanfaatkan **ontologi** dan **Semantic Web Rule Language (SWRL)** sebagai fondasi utama dalam penalaran semantik. Latar belakang penelitian ini berangkat dari permasalahan meningkatnya jumlah game digital yang beredar di pasaran, yang menyebabkan kesulitan bagi pengguna dalam menemukan game yang sesuai dengan preferensi dan karakteristik pribadi. Sistem rekomendasi konvensional seperti *content-based filtering* dan *collaborative filtering* masih memiliki keterbatasan, terutama dalam memahami konteks semantik antar entitas dan pengetahuan domain yang kompleks.

Penelitian ini mengusulkan pendekatan semantik melalui pemodelan ontologi game yang merepresentasikan hubungan antar konsep seperti genre, platform, rating, dan karakteristik pemain. Ontologi tersebut dikombinasikan dengan aturan inferensi menggunakan SWRL untuk menghasilkan rekomendasi yang lebih kontekstual dan akurat. Pengembangan sistem dilakukan dengan metode **Iterative Development**, yang memungkinkan perbaikan bertahap pada setiap siklus pengujian dan evaluasi. Arsitektur sistem dirancang dalam empat lapisan utama, yaitu *presentation layer*, *application layer*, *semantic layer* sebagai inovasi utama, dan *data layer*.

Implementasi sistem meliputi perancangan diagram fungsional seperti *use case diagram*, *activity diagram*, serta model basis data (*Entity Relationship Diagram*) untuk mendukung integrasi antarkomponen. Pada tahap perancangan pengetahuan, ontologi game dikembangkan melalui beberapa iterasi hingga mencapai struktur final yang tervalidasi, mencakup instansiasi data serta relasi logis antar entitas. Inovasi utama penelitian ini terletak pada integrasi *rules-based reasoning* dengan riwayat pencarian dan pembelian pengguna, membentuk **algoritma rekomendasi hibrida** yang lebih adaptif terhadap perilaku pengguna.

Hasil awal menunjukkan bahwa sistem mampu memberikan rekomendasi yang lebih relevan dibandingkan pendekatan non-semantik. Selain itu, pendekatan berbasis ontologi memungkinkan fleksibilitas dalam ekspansi domain dan peningkatan kualitas inferensi di masa depan. Penelitian ini diharapkan dapat

memberikan kontribusi dalam pengembangan sistem rekomendasi cerdas berbasis semantik di ranah e-commerce dan hiburan digital.

Kata Kunci: Sistem rekomendasi, Ontologi, Semantic Web Rule Language (SWRL), Web semantik, Iterative development, Algoritma hibrida.

ABSTRACT

*This research aims to design and implement a web-based game recommendation system that leverages **ontology** and the **Semantic Web Rule Language (SWRL)** as the core framework for semantic reasoning. The study is motivated by the increasing number of digital games available on the market, which makes it difficult for users to discover games that match their individual preferences and characteristics. Conventional recommendation approaches such as content-based filtering and collaborative filtering still suffer from limitations, particularly in understanding semantic relationships among entities and handling complex domain knowledge.*

*This study proposes a semantic approach through the development of a **game ontology** that represents relationships among concepts such as genre, platform, rating, and player characteristics. The ontology is combined with SWRL inference rules to generate more contextual and accurate recommendations. The system is developed using an **Iterative Development** method, allowing continuous improvement through testing and refinement cycles. The system architecture consists of four primary layers: presentation layer, application layer, semantic layer—as the main innovation—and data layer.*

*The implementation includes the design of functional diagrams such as use case, activity, and entity-relationship diagrams to support component integration. During the knowledge modeling phase, the game ontology was iteratively refined and validated, covering data instantiation and logical relationships among entities. The main contribution of this research lies in the integration of **rule-based reasoning** with user behavior, including search and purchase history, forming a **hybrid recommendation algorithm** that adapts dynamically to user preferences.*

Preliminary results show that the system provides more relevant recommendations compared to non-semantic approaches. Moreover, the ontology-based framework offers flexibility for domain expansion and enhances inference quality for future applications. This research is expected to contribute to the development of intelligent semantic-based recommendation systems in the domains of e-commerce and digital entertainment.

Keywords: *Recommendation system, Ontology, Semantic Web Rule Language (SWRL), Semantic Web, Iterative development, Hybrid algorithm.*

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan YME atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan tugas akhir ini dengan judul *“Sistem Algoritma Rekomendasi Game pada Website Berbasis Ontologi dan SWRL (Semantic Web Rule Language)”* dengan lancar dan tepat waktu.

Penulis menyadari bahwa skripsi ini tidak akan selesai tanpa dukungan dan bantuan dari berbagai pihak. Dengan penuh rasa terima kasih, saya ingin menyampaikan penghargaan sebesar-besarnya kepada:

1. Tuhan YME yang senantiasa melimpahkan rahmat, hidayah, kesehatan, kebahagiaan, serta kelancaran kepada penulis, sehingga dapat menyelesaikan penyusunan skripsi ini. Segala puji dan syukur penulis haturkan atas segala nikmat, dan pertolongan yang tiada henti serta kekuatan yang telah Dia anugerahkan selama proses penulisan tugas akhir ini.
2. Teristimewa untuk Kedua Orangtua tercinta, yang telah memberikan kasih sayang, nasehat, motivasi, memenuhi kebutuhan penulis, dukungan serta Doa yang tiada henti kepada penulis selama melalui proses perkuliahan, penulisan tugas akhir ini sampai saat ini.

DAFTAR ISI

LEMBAR PERSETUJUAN.....	ii
LEMBAR ORISINALITAS	iii
ABSTRAK	iv
ABSTRACT.....	vi
KATA PENGANTAR	viii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
BAB I.....	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Tugas Akhir.....	3
1.4 Batasan Masalah.....	3
1.5 Metode Tugas akhir.....	4
1.5.1 Keunggulan Metode	6
1.5.2 Pengumpulan Data	6
1.5.3 Desain Sistem.....	7
1.5.3.1 Arsitektur Sistem	7
1.5.3.2 Rencana Alur Pengembangan.....	8
BAB 2 TINJAUAN PUSTAKA	11
2.1 Landasan Teori	11
2.2 Sistem pemberi rekomendasi.....	12
2.2.1 <i>Content-Based Filtering</i>	12

2.2.2	<i>Collaborative Filtering</i>	13
2.3	<i>Ontologi dan Semantic Web</i>	14
2.4	<i>Semantic Web Rule Language (SWRL)</i>	15
2.5	Penerapan Ontologi dan SWRL pada Sistem pemberi rekomendasi Produk Game	16
BAB 3 PERANCANGAN DAN IMPLEMENTASI SISTEM.....		18
3.1	Pendekatan <i>Iterative Development</i> dalam tugas akhir.....	18
3.2	<i>Arsitektur Sistem Final</i>	20
3.2.1	<i>Presentation Layer</i>	21
3.2.2	<i>Application Layer</i>	21
3.2.3	<i>Semantic Layer - Inovasi Utama</i>	22
3.2.4	<i>Data Layer</i>	23
3.3	Perancangan Fungsional Sistem	23
3.3.1	Functional Requirement	24
3.3.2	Use Case Diagram.....	27
3.3.3	Activity Diagram Rekomendasi Produk	29
3.3.4	Activity Diagram Daftar Akun.....	30
3.3.5	Activity Diagram Login Akun	31
3.3.6	Activity Diagram Pencarian Produk	33
3.3.7	Activity Diagram Belanja Utama.....	34
3.3.8	Activity Diagram Pengelolaan Keranjang Belanja	35
3.3.9	Activity Diagram Alur Proses Checkout	36
3.3.10	Entitiy Relationship Diagram.....	37
3.4	Pemodelan Pengetahuan: Ontologi Game	39
3.4.1	Evolusi Ontologi Melalui Iterasi.....	39
3.4.2	Struktur Final Ontologi	40

3.4.3	Instance Data dan Validasi.....	40
3.5	Integrasi Sistem dan <i>Deployment</i>	41
3.5.1	Evolusi dari Konsep Formal ke Implementasi Praktis.....	41
3.5.2	Arsitektur Algoritma Hybrid.....	42
3.5.3	Pilar Pertama: <i>Rules-Based</i>	43
3.5.4	Pilar Kedua: <i>History Pencarian</i>	44
3.5.5	Pilar Ketiga: <i>Riwayat Pembelian</i>	45
3.6	Integrasi Sistem dan <i>Deployment</i>	47
3.6.1	Integrasi Antar Komponen.....	47
3.6.2	<i>Testing</i> dan <i>Validation</i>	47
3.7	Evaluasi dan <i>Lessons Learned</i>	48
BAB 4 PENYELESAIAN PERMASALAHAN.....		49
4.1	Metodologi Pengujian	49
4.2	Skenario dan Hasil Pengujian.....	49
4.3	Tampilan <i>Website</i> Secara Keseluruhan	49
4.4	Analisis dan Pembahasan Hasil.....	49
BAB 5 KESIMPULAN DAN SARAN		50
5.1	Kesimpulan.....	50
5.2	Saran.....	50
DAFTAR PUSTAKA		50
LAMPIRAN.....		54

DAFTAR GAMBAR

Gambar 1. 1 Model Pengembangan Iteratif dan Inkremental	5
Gambar 1. 2 Diagram Alur Sistem.....	8
Gambar 3. 1 Arsitektur Sistem Final	20
Gambar 3. 2 Use Case Diagram.....	27
Gambar 3. 3 Rekomendasi Produk.....	29
Gambar 3. 4 Daftar Akun.....	30
Gambar 3. 5 Login Akun	31
Gambar 3. 6 Pencarian Produk.....	33
Gambar 3. 7 Alur Belanja Utama.....	34
Gambar 3. 8 Alur Pengelolaan Keranjang	35
Gambar 3. 9 Alur Proses Checkout.....	36
Gambar 3. 10 ERD Pengaruh Data Pengguna terhadap Sistem Skoring	37

DAFTAR TABEL

Tabel 3. 1 Functional Requirement.....	24
--	----

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam beberapa tahun terakhir, industri hiburan digital, khususnya platform distribusi game, mengalami lonjakan yang signifikan seiring meluasnya adopsi teknologi dalam berbagai aspek kehidupan. Platform seperti Steam, Epic Games Store, dan PlayStation Store telah bertransformasi menjadi ekosistem cerdas yang menuntut efisiensi dan personalisasi layanan untuk mengatasi tantangan melimpahnya pilihan, atau yang dikenal sebagai *information overload* [1]. Untuk mengatasi hal tersebut, sistem rekomendasi menjadi komponen krusial yang mampu mempersonalisasi konten dan membantu pemain menemukan game yang relevan di antara ribuan judul yang tersedia.

Dengan meningkatnya volume game dan preferensi pemain yang semakin beragam, kebutuhan akan sistem rekomendasi yang cerdas menjadi semakin mendesak. Penelitian dalam domain ini menekankan pentingnya sistem yang mampu mengolah informasi produk yang kompleks, seperti genre, mekanisme permainan (*gameplay*), tema, dan platform untuk memberikan rekomendasi yang akurat [2]. Penelitian tersebut menggarisbawahi peran penting pemodelan domain pengetahuan secara formal untuk menjawab tantangan *information overload*, sekaligus membuka peluang pengembangan metode yang lebih fleksibel.

Pendekatan multidimensional yang mengintegrasikan antara atribut game yang mendalam dengan preferensi dan profil pemain terbukti mampu meningkatkan kualitas rekomendasi secara signifikan [3]. Temuan ini memperkuat perlunya sistem yang tidak hanya mencocokkan kata kunci, tetapi juga memahami relasi antar konsep dalam domain game. Tujuannya tidak hanya untuk meningkatkan akurasi, tetapi juga untuk mengurangi *decision fatigue* (kelelahan dalam mengambil keputusan) yang dialami pemain saat dihadapkan pada katalog game yang sangat luas.

Berbagai pendekatan telah dikembangkan untuk mengatasi tantangan ini. Metode populer seperti *deep learning* sering kali memerlukan daya komputasi yang tinggi dan bersifat "kotak hitam" (*black box*). Sebagai alternatif, pemanfaatan teknologi Semantic Web memungkinkan representasi pengetahuan secara formal dan dapat dimaknai oleh mesin [4]. Dalam ekosistem ini, SWRL (Semantic Web Rule Language) berfungsi sebagai bahasa aturan yang kuat untuk mendefinisikan aturan semantik kompleks dan melakukan penalaran (*reasoning*) pada ontologi. Dengan SWRL, sistem dapat menghasilkan rekomendasi game yang terstruktur dan dapat dijelaskan (*explainable*) berdasarkan relasi logis antar entitas yang telah didefinisikan, seperti hubungan antara genre, mekanik, dan preferensi pemain.

1.2 Rumusan Masalah

Pertumbuhan masif pada platform distribusi game digital telah menciptakan tantangan dalam merekomendasikan produk yang relevan, terutama karena game memiliki atribut kompleks seperti genre dan mekanisme permainan yang sulit ditangani sistem konvensional. Oleh karena itu, penelitian ini mengusulkan pendekatan berbasis ontologi dan aturan SWRL untuk merepresentasikan pengetahuan domain game secara semantik, guna meningkatkan akurasi dan relevansi rekomendasi yang diberikan kepada pemain. Berdasarkan hal tersebut, maka rumusan masalah yang dikaji adalah:

1. Bagaimana merancang model ontologi yang komprehensif untuk merepresentasikan domain *video game*, dengan memodelkan entitas, atribut-atribut kompleks (seperti genre, mekanisme permainan, tema, platform, mode permainan), dan relasi semantik antar entitas tersebut?
2. Bagaimana mengembangkan seperangkat aturan logika inferensi menggunakan SWRL yang dapat melakukan penalaran atas ontologi *video game* untuk menyimpulkan rekomendasi yang dipersonalisasi berdasarkan profil dan preferensi historis pemain?

1.3 Tujuan Tugas Akhir

Tugas akhir ini memiliki beberapa tujuan utama sebagai berikut:

1. Membangun sebuah model ontologi domain video game yang mampu merepresentasikan atribut-atribut kompleks seperti genre, mekanisme permainan (*gameplay*), tema, dan platform, serta hubungan semantik antar entitas tersebut.
2. Mengembangkan dan mengimplementasikan aturan-aturan logika menggunakan SWRL yang dapat melakukan penalaran (*reasoning*) pada ontologi untuk menghasilkan rekomendasi game yang sesuai dengan profil dan preferensi pemain.
3. Membangun sebuah prototipe sistem pemberi rekomendasi berbasis web yang dapat menyajikan hasil rekomendasi yang dipersonalisasi kepada pemain berdasarkan aturan yang telah didefinisikan.

Ontologi dan sistem pemberi rekomendasi yang dikembangkan ini bertujuan untuk meningkatkan relevansi dan akurasi rekomendasi game, efisiensi penemuan konten (*content discovery*), serta kepuasan pemain. Selain itu, sistem ini diharapkan dapat menjadi sebuah solusi alternatif yang ringan dan *explainable* (dapat dijelaskan), tanpa memerlukan sumber daya komputasi masif seperti yang dibutuhkan oleh pendekatan *deep learning*

1.4 Batasan Masalah

Untuk menjaga fokus dan keterlaksanaan tugas akhir dalam jangka waktu yang terbatas serta memperhitungkan sumber daya yang tersedia, maka tugas akhir ini memiliki batasan sebagai berikut:

1. Ruang Lingkup Produk Terbatas pada Kategori Video Game PC

Tugas akhir ini hanya mencakup produk berupa video game untuk platform PC yang telah didefinisikan dalam ontologi. Game dari platform lain seperti konsol atau mobile tidak dimasukkan dalam sistem. Pembatasan ini ditetapkan untuk menjaga kompleksitas ontologi tetap dapat dikelola dan fokus pada atribut-atribut spesifik game PC.

2. Jumlah Data Game Terbatas dan Bersifat Statis

Data video game yang digunakan dalam pengujian sistem hanya berjumlah puluhan entri yang dimasukkan secara manual ke dalam basis data dan ontologi. Hal ini disebabkan keterbatasan waktu dalam memperoleh serta mengklasifikasikan data game secara masif dari sumber platform digital seperti Steam atau IGDB.

3. Preferensi Pemain Tidak Diperoleh dari Data Historis Riil

Preferensi pemain ditentukan secara eksplisit melalui input (misalnya, form pemilihan genre atau fitur favorit) dan bukan dari data historis riil seperti daftar game yang pernah dimainkan, waktu bermain, atau wishlist. Hal ini dilakukan karena sistem belum dilengkapi dengan modul untuk melacak interaksi pemain secara otomatis.

4. Penerapan SWRL Terbatas pada Aturan Inferensi Dasar

Aturan semantik yang ditulis dalam SWRL hanya mencakup kombinasi dasar antara atribut game dan preferensi pemain, seperti kecocokan genre, kesamaan mekanisme permainan, atau platform yang dimiliki. Aturan yang sangat kompleks tidak diimplementasikan karena keterbatasan dalam pengujian dan optimasi reasoner untuk sistem skala kecil.

5. Proses Pembuatan Ontologi Dilakukan Secara Manual


Ontologi video game (file.owl) disusun secara manual menggunakan OwlReady2, termasuk definisi kelas, properti, dan individu (data game). Proses ini dilakukan secara manual karena belum adanya alat otomatis yang dapat menghasilkan ontologi game yang terstruktur langsung dari API platform digital.

1.5 Metode Tugas akhir

Tugas akhir ini menggunakan pendekatan *Iterative Development* [5], yaitu sebuah metode pengembangan sistem yang dilakukan secara bertahap melalui siklus pengulangan (iterasi). Setiap iterasi mencakup proses analisis kebutuhan, perancangan, implementasi, dan pengujian yang dilakukan secara berulang hingga sistem mencapai fungsionalitas dan

stabilitas yang diinginkan. Pendekatan ini sangat relevan untuk pengembangan sistem berbasis kecerdasan buatan dan *semantic web* karena memungkinkan penyempurnaan sistem secara progresif dan adaptif terhadap temuan baru atau kebutuhan pengguna [6].

Pemilihan metode ini didasarkan pada karakteristik proyek pengembangan sistem pemberi rekomendasi *game* berbasis ontologi dan SWRL, yang secara inheren memerlukan validasi dan penyempurnaan bertahap. Proses ini mencakup beberapa tahapan krusial, mulai dari perancangan model ontologi *game*, implementasi aturan-aturan logika SWRL, hingga integrasi akhir dengan antarmuka pengguna. Dengan pendekatan iteratif, setiap komponen tersebut dapat dikembangkan secara modular, diuji secara terpisah, dan disempurnakan berdasarkan hasil evaluasi di setiap siklusnya.



Gambar 1. 1 Model Pengembangan Iteratif dan Inkremental [7]

Berdasarkan Gambar 1.1 tersebut, digambarkan tahapan *Iterative and Incremental Development* yang digunakan dalam pengembangan Sistem Algoritma Rekomendasi Game pada Website Berbasis Ontologi dan SWRL. Proses dimulai dari tahap *initial planning* untuk menentukan tujuan awal, ruang lingkup, serta sasaran pengembangan sistem, yaitu membangun platform yang mampu memberikan rekomendasi game secara personal dan relevan. Selanjutnya, pada tahap *requirements*, diidentifikasi kebutuhan sistem seperti representasi pengetahuan domain video game, profil pemain, preferensi, serta aturan logika rekomendasi berbasis SWRL. Tahap

planning digunakan untuk menyusun rencana implementasi tiap iterasi, termasuk pembagian pekerjaan dan prioritas fitur.

Pada tahap *analysis & design*, dilakukan perancangan arsitektur sistem berbasis web, struktur ontologi video game, dan integrasi aturan SWRL untuk mengatur logika rekomendasi. Tahap *implementation* mencakup pembangunan sistem menggunakan *framework* Flask dan *library* Owlready2 untuk mengintegrasikan ontologi OWL dengan *reasoning engine*. Selanjutnya, tahap *testing* dilakukan untuk menguji akurasi dan relevansi rekomendasi, serta kinerja sistem. Setelah itu, sistem masuk tahap *deployment* dengan mengimplementasikan versi yang sudah stabil pada lingkungan uji. Akhirnya, pada tahap *evaluation*, dilakukan penilaian terhadap hasil iterasi, mengumpulkan umpan balik, dan mengidentifikasi perbaikan yang akan diterapkan pada iterasi berikutnya. Siklus ini diulang hingga sistem dapat memberikan rekomendasi game yang akurat, adaptif, dan sesuai kebutuhan pemain tanpa memerlukan data historis dalam jumlah besar.

1.5.1 Keunggulan Metode

1. Fleksibel sehingga selama proses pengujian ditemukan kekurangan dalam model ontologi *game* atau logika aturan SWRL, perbaikan dapat langsung diimplementasikan pada siklus iterasi berikutnya.
2. Validasi berupa pengujian dan validasi fungsionalitas dilakukan sejak tahap awal, sehingga potensi kesalahan desain atau logika dapat dideteksi dan diperbaiki lebih dini.
3. Adaptif terhadap keterbatasan waktu dan sumber daya dengan berfokus dari setiap iterasi dapat disesuaikan dengan batasan Tugas Akhir, misalnya dengan memprioritaskan implementasi dan pengujian untuk subset genre game tertentu terlebih dahulu.

1.5.2 Pengumpulan Data

Data yang digunakan dalam sistem terdiri dari dua jenis:

1. Data Video Game

Data ini meliputi atribut-atribut game yang kompleks seperti genre, mekanisme permainan (gameplay), tema, platform, dan mode permainan. Data dikumpulkan secara manual dari basis data game publik seperti IGDB (*Internet Game Database*) dan SteamDB, kemudian dimasukkan ke dalam basis data sistem serta ontologi dalam format .owl.

2. Data Preferensi Pemain

Preferensi ini dikumpulkan melalui input eksplisit dari pemain, seperti genre favorit, mekanisme permainan yang disukai, atau platform yang dimiliki. Sistem juga dirancang untuk dapat menyimpan data implisit seperti game yang pernah dimainkan (*play history*) dan daftar keinginan (*wishlist*) untuk digunakan dalam proses rekomendasi lanjutan.

1.5.3 Desain Sistem

1.5.3.1 Arsitektur Sistem

Sistem ini terdiri dari beberapa komponen utama:


- a. *Frontend*: Presentasi visual dan interaksi pengguna diimplementasikan sebagai aplikasi web dengan teknologi HTML, CSS, dan Bootstrap, serta dirender menggunakan sistem *templating* dari Flask.
- b. *Backend*: Inti dari aplikasi dijalankan oleh *framework* Flask (Python), yang menangani logika bisnis. Konektivitas ke basis data dikelola oleh SQLAlchemy (ORM), sementara proses penalaran semantik ditangani oleh modul SWRL/OWL.
- c. *Ontologi*: Representasi pengetahuan domain video game disusun dalam format OWL dan diakses melalui *library* Owlready2. Ontologi ini mendefinisikan kelas-kelas utama (contoh: Game, Genre) dan properti yang merepresentasikan hubungan antar entitas.
- d. *Reasoning Engine*: Logika inferensi untuk menghasilkan rekomendasi diimplementasikan menggunakan aturan-aturan

SWRL. *Engine* ini bertugas menarik kesimpulan baru dari basis pengetahuan ontologi sesuai dengan input preferensi pemain

- e. *Database*: Untuk penyimpanan data statis seperti profil pemain, detail game, dan data interaksi, sistem menggunakan MySQL sebagai sistem manajemen basis data relasional (RDBMS).

1.5.3.2 Rencana Alur Pengembangan

Berikut adalah alur proses sistem dari awal hingga hasil rekomendasi muncul:



Gambar 1. 2 Diagram Alur Sistem

Diagram pada Gambar 1.2 mengilustrasikan alur kerja sistem rekomendasi game dari awal hingga akhir. Berikut adalah penjelasan untuk setiap tahapannya:

1. Pengumpulan Data

Tahap awal adalah pengumpulan data, di mana informasi mengenai video game dikumpulkan dari berbagai sumber seperti basis data publik (misalnya, IGDB atau SteamDB). Data ini mencakup atribut-

atribut esensial seperti genre, mekanisme permainan (*gameplay*), tema, dan platform.

2. Pembangunan Ontologi

Selanjutnya, dilakukan pembangunan ontologi menggunakan perangkat lunak seperti OwlReady2. Data game yang telah dikumpulkan ditransformasikan menjadi sebuah model pengetahuan formal, di mana setiap game menjadi *individu (instance)* dan atributnya didefinisikan melalui kelas-kelas (misalnya, Game, Genre), properti, dan relasi logis.

3. Pemodelan Aturan SWRL

Pada tahap pemodelan aturan SWRL, logika untuk sistem rekomendasi didefinisikan. Aturan-aturan ini ditulis untuk melakukan inferensi atau penalaran (*reasoning*) terhadap ontologi. Sebagai contoh, sebuah aturan dapat menyatakan:

“Jika seorang pemain menyukai genre ‘RPG’ dan memiliki platform ‘PC’, maka rekomendasikan game yang merupakan anggota kelas RPG dan tersedia untuk PC.”

4. Input Preferensi Pemain

Sistem kemudian menerima input preferensi pemain melalui antarmuka web. Pemain memasukkan preferensi mereka, seperti genre favorit atau platform yang dimiliki. Data ini berfungsi sebagai pemicu (*trigger*) bagi *reasoning engine* untuk memulai proses pencocokan.

5. Integrasi Ontologi ke Website

Tahap integrasi adalah proses teknis di mana model ontologi dan aturan SWRL dihubungkan ke dalam *backend* sistem yang dibangun dengan Flask. Integrasi ini, sering kali menggunakan *library* seperti OwlReady2, memungkinkan aplikasi web untuk mengirim kueri ke *reasoning engine* dan menerima hasilnya.

6. Hasil Rekomendasi

Terakhir, hasil rekomendasi disajikan kepada pemain. Berdasarkan preferensi yang diinput dan hasil penalaran logis terhadap ontologi,

sistem menampilkan daftar game yang paling sesuai. Hasil ini bukan sekadar pencocokan kata kunci, melainkan kesimpulan yang ditarik dari hubungan semantik yang telah dimodelkan.

BAB 2

TINJAUAN PUSTAKA

2.1 Landasan Teori

Penelitian ini didasarkan pada persimpangan lima pilar teori utama: konsep sistem pemberi rekomendasi, teknologi *Semantic Web* dan ontologi, bahasa aturan SWRL, kerangka kerja pengembangan web menggunakan Flask, serta mekanisme penalaran semantik. Kombinasi dari kelima pilar ini membentuk dasar untuk membangun sebuah sistem rekomendasi game yang cerdas dan berbasis logika.

Berbagai metode rekomendasi seperti *content-based filtering*, *collaborative filtering*, dan pendekatan *hybrid* telah terbukti efektif dalam menyajikan item yang relevan kepada pengguna. Secara khusus, pendekatan *hybrid* menunjukkan potensi besar dalam meningkatkan kualitas saran untuk produk hiburan digital yang kompleks seperti video game [8], yang menjadi tujuan utama dari sistem pemberi rekomendasi.

Untuk merepresentasikan pengetahuan domain secara formal, digunakan ontologi dalam format OWL. Model ini mendefinisikan entitas-entitas kunci dalam dunia game—seperti genre, mekanisme permainan, dan preferensi pemain—beserta relasi di antara mereka. Kemampuan penalaran sistem kemudian diperluas dengan aturan SWRL, yang memungkinkan inferensi logika spesifik, misalnya: “*seorang pemain yang menyukai genre ‘Strategy’ harus direkomendasikan game lain yang juga memiliki genre ‘Strategy’*” [9].

Implementasi teknis dari sistem ini menggunakan *framework* Flask sebagai jembatan antara antarmuka pengguna dan logika *backend*. Lapisan semantik dioperasikan oleh *library* Owlready2, yang bertanggung jawab untuk memanipulasi ontologi dan mengeksekusi aturan. Proses inferensi itu sendiri dijalankan oleh *reasoning engine* seperti HermiT untuk menghasilkan rekomendasi yang dipersonalisasi bagi setiap pemain [10].

Oleh karena itu, penggabungan ontologi dan SWRL menawarkan sebuah solusi alternatif yang kuat untuk personalisasi di platform distribusi game. Pendekatan ini memiliki keunggulan berupa transparansi dalam logika rekomendasinya serta efisiensi komputasi yang lebih ringan dibandingkan metode lainnya.

2.2 Sistem pemberi rekomendasi

Dalam literatur, terdapat tiga pendekatan fundamental untuk membangun sistem rekomendasi: *collaborative filtering*, *content-based filtering*, dan *hybrid/Rules-based* [11]. *Collaborative filtering* bekerja dengan menemukan pemain lain dengan selera serupa, sementara *content-based filtering* menganalisis atribut intrinsik dari item itu sendiri dan mencocokkannya dengan profil pemain. Pendekatan *hybrid*, seperti yang dikaji oleh Javad et al., sering kali menggabungkan kekuatan kedua metode tersebut dan memperkayanya dengan pengetahuan spesifik domain untuk mencapai akurasi yang lebih tinggi. Pada intinya, semua pendekatan ini merupakan teknologi penyaringan informasi yang dirancang untuk menyajikan konten yang paling relevan dan dipersonalisasi kepada pengguna.

2.2.1 Content-Based Filtering

Content-Based Filtering merupakan pendekatan yang menyarankan item kepada pemain dengan menganalisis atribut intrinsik dari item tersebut. Logikanya sederhana: jika seorang pemain menyukai sebuah game, maka ia akan direkomendasikan game lain yang memiliki karakteristik serupa. Pendekatan ini berfokus pada fitur-fitur game seperti genre, mekanisme permainan (*gameplay*), tema, dan platform. Sebagai contoh, jika seorang pemain sering memainkan game strategi bertema fantasi, maka sistem akan cenderung menyarankan game lain yang juga memiliki genre dan tema serupa. Poin-poin kunci *Content-Based Filtering*:

1. Mendasarkan rekomendasi pada analisis atribut item.
2. Beroperasi secara independen untuk setiap pemain, tanpa memerlukan data komunitas.
3. Efektif untuk pemain baru (*new players*) karena tidak bergantung pada riwayat interaksi yang panjang.

4. Kelemahannya adalah kurangnya variasi; rekomendasi sering kali terbatas pada item yang sangat mirip dengan yang sudah disukai.
5. Sulit untuk menemukan hal-hal baru (*serendipity*), karena sistem jarang menyarankan item di luar zona nyaman preferensi pemain.

2.2.2 Collaborative Filtering

Collaborative Filtering adalah sebuah pendekatan yang menghasilkan rekomendasi dengan mengidentifikasi kesamaan selera di antara sekelompok pemain. Asumsi dasarnya adalah jika dua pemain memberikan penilaian atau memiliki riwayat permainan yang serupa di masa lalu, mereka kemungkinan besar akan menyukai game yang sama di masa depan. Metode ini tidak menganalisis atribut intrinsik dari sebuah game, melainkan berfokus sepenuhnya pada pola interaksi komunitas. *Collaborative Filtering* umumnya dibagi menjadi dua kategori utama:

1. *User-Based Collaborative Filtering*, yang bekerja dengan menemukan sekelompok pemain lain dengan selera serupa, lalu merekomendasikan game yang disukai oleh kelompok tersebut.
2. *Item-Based Collaborative Filtering*, yang bekerja dengan menemukan game-game yang sering kali disukai atau dimainkan bersama oleh komunitas pemain yang sama, lalu merekomendasikannya.

Poin-Poin Kunci *Collaborative Filtering*:

- a. Rekomendasi dihasilkan tanpa menganalisis fitur game (seperti genre atau tema).
- b. Sangat bergantung pada ketersediaan data interaksi komunitas dalam jumlah besar.
- c. Mampu menciptakan rekomendasi yang mengejutkan (*serendipitous*), karena dapat menghubungkan game dari genre yang berbeda.
- d. Menghadapi masalah *cold-start* yakni kesulitan memberikan rekomendasi untuk pemain atau game baru yang belum memiliki data interaksi.

- e. Kinerjanya meningkat seiring dengan bertambahnya volume data interaksi pemain.

Sebagai pelengkap, banyak sistem modern mengadopsi pendekatan *Hybrid Recommender System*. Sistem ini dirancang untuk mengombinasikan kekuatan dari berbagai metode seperti *content-based* dan *collaborative filtering* untuk menutupi kelemahan masing-masing dan pada akhirnya menghasilkan rekomendasi yang lebih akurat dan personal.

2.3 *Ontologi dan Semantic Web*

Dalam sistem rekomendasi berbasis preferensi, ontologi berfungsi untuk memodelkan atribut game dan preferensi pemain dalam format semantik, yang memungkinkan sistem untuk memahami konteks secara lebih mendalam [12]. Pendekatan semantik ini memberikan kemampuan untuk merepresentasikan fitur-fitur kompleks sebuah game (seperti genre, mekanisme permainan, dan tema visual) dengan presisi tinggi. Studi yang telah dilakukan dengan algoritma SOBPA, menunjukkan bahwa penggunaan ontologi yang mendalam untuk memodelkan domain produk dan profil pengguna dapat secara signifikan meningkatkan akurasi dan personalisasi dibandingkan metode konvensional [13].

Kemampuan utama dari penggunaan ontologi adalah dukungannya terhadap proses penalaran (*reasoning*). Sistem dapat melakukan inferensi atau menarik kesimpulan logis mengenai relasi antara konsep-konsep game dan preferensi pemain. Dengan menggunakan perangkat seperti OwlReady2 [14] untuk membangun representasi logis dan mengintegrasikannya dengan aturan SWRL, sistem rekomendasi yang dihasilkan menjadi lebih fleksibel dan *explainable* (dapat dijelaskan). Selain itu, logika aturan dapat dimodifikasi dengan mudah tanpa perlu melakukan pelatihan ulang model statistik yang memakan waktu.

Secara keseluruhan, pemanfaatan ontologi dalam sistem rekomendasi game menawarkan keunggulan signifikan dalam hal representasi pengetahuan semantik, fleksibilitas desain, dan transparansi logika. Melalui integrasi dengan teknologi *Semantic Web* dan aturan SWRL, sistem ini mampu memberikan rekomendasi

game secara lebih cerdas dan efisien, di mana setiap saran yang dihasilkan dapat dilacak dan dijelaskan secara formal.

2.4 *Semantic Web Rule Language (SWRL)*

Semantic Web Rule Language (SWRL) adalah sebuah bahasa aturan yang memperluas kapabilitas *Web Ontology Language (OWL)* dengan memungkinkan penulisan aturan logika berbentuk *if-then*. SWRL mengintegrasikan sintaksis dari OWL DL dan RuleML, menciptakan sebuah sistem yang dapat melakukan inferensi secara otomatis berdasarkan hubungan semantik yang didefinisikan dalam ontologi [17]. Dalam konteks sistem rekomendasi, SWRL berfungsi untuk mengekspresikan logika pemilihan game yang cocok dengan profil pemain, seperti preferensi genre, platform yang dimiliki, atau mekanisme permainan favorit.

Penerapan SWRL dalam sistem rekomendasi personal telah terbukti efektif di berbagai domain. Sebuah studi, misalnya, berhasil mengembangkan sistem rekomendasi menu makanan untuk binaragawan menggunakan ontologi dan aturan SWRL, di mana sistem tersebut mampu mencapai nilai *precision* 0,866 dan *recall* 1,0. Penelitian serupa juga melaporkan pencapaian *F1-score* yang tinggi, membuktikan bahwa pendekatan berbasis aturan semantik ini secara konsisten mampu meningkatkan akurasi dalam rekomendasi yang dipersonalisasi [15].

Fleksibilitas SWRL tidak terbatas pada rekomendasi produk. Dalam domain lain seperti diagnosis medis, pendekatan ini juga dimanfaatkan untuk membangun sistem pendukung keputusan. Aturan semantik memungkinkan sistem untuk memetakan gejala pasien ke diagnosis potensial, dengan keunggulan utama yaitu logika sistem dapat diperbarui tanpa memerlukan proses pelatihan ulang model yang mahal seperti pada pendekatan *machine learning* [16].

Kesimpulannya, SWRL menyediakan kerangka kerja logika yang fleksibel dan transparan untuk mendukung proses penalaran berbasis ontologi. Keunggulan utamanya terletak pada kemudahan modifikasi aturan dan kemampuannya untuk berintegrasi dengan *reasoning engine* standar seperti Pellet dan HermiT. Dalam konteks sistem pemberi rekomendasi video game, SWRL sangat relevan untuk

menjembatani preferensi pemain dengan atribut-atribut game yang kompleks melalui aturan-aturan semantik yang logis dan adaptif.

2.5 Penerapan Ontologi dan SWRL pada Sistem pemberi rekomendasi Produk Game

Tujuan utama penerapan ontologi dalam sistem rekomendasi game adalah untuk merepresentasikan pengetahuan domain secara formal. Ini mencakup pemodelan atribut-atribut kompleks seperti genre, platform, mekanisme permainan, dan preferensi pemain [13]. Dengan menggunakan *Web Ontology Language* (OWL), berbagai game dapat diklasifikasikan ke dalam sebuah hierarki konsep yang terstruktur dan dapat diproses oleh mesin. Relasi antar entitas, misalnya ‘Game dengan genre *Strategy*’ cocok untuk ‘Pemain yang menyukai tantangan taktis’, direpresentasikan sebagai *triple* RDF yang menjadi dasar bagi proses penalaran.

Integrasi aturan SWRL ke dalam ontologi game memperkaya sistem dengan kemampuan untuk memberikan rekomendasi secara otomatis berdasarkan kombinasi preferensi pemain. Sebagai contoh, aturan seperti ‘*Jika seorang pemain memiliki platform ‘PC’ dan menyukai genre ‘RPG’, maka rekomendasikan game RPG yang tersedia di PC*’ dapat dieksekusi oleh *reasoner* seperti HermiT atau Pellet [14]. Aturan semacam ini memungkinkan sistem untuk menyimpulkan kecocokan game bahkan ketika informasinya tidak dinyatakan secara eksplisit, karena penalaran semantik mampu mengisi kekosongan informasi melalui proses inferensi.

Pendekatan berbasis SWRL dalam konteks rekomendasi game ini terbukti lebih ringan jika dibandingkan dengan metode berbasis *deep learning*, terutama dalam hal kebutuhan komputasi dan transparansi logika. Sistem ini tidak bergantung pada data historis dalam volume masif, sehingga cocok untuk skenario di mana data interaksi pemain terbatas [17]. Hasil pengujian pada sistem serupa menunjukkan bahwa performa dari sisi kecepatan penalaran dan relevansi rekomendasi sangat positif, meskipun inputnya masih terbatas pada preferensi yang diberikan secara eksplisit oleh pemain.

Secara teknis, implementasi sistem ini dibangun menggunakan *framework* Python Flask, yang terhubung dengan *file* ontologi .owl melalui *library* Owlready2. Alur kerjanya dimulai ketika pemain mengisi *form* preferensi seperti genre favorit, platform yang dimiliki, atau mekanisme permainan yang disukai melalui antarmuka web. Input ini kemudian digunakan oleh sistem untuk melakukan penalaran terhadap ontologi dan aturan SWRL, yang pada akhirnya menghasilkan daftar rekomendasi yang disajikan secara *real-time*.

Kesimpulannya, penerapan ontologi dan SWRL pada sistem pemberi rekomendasi game memberikan sebuah solusi yang cerdas dan efisien untuk menyajikan konten yang relevan secara personal. Dengan memanfaatkan struktur semantik dan logika inferensi, sistem ini tidak hanya mampu meningkatkan akurasi rekomendasi, tetapi juga menawarkan sebuah pendekatan yang hasilnya dapat dijelaskan secara formal, mudah untuk dikembangkan, dan ringan dari sisi infrastruktur teknis.

BAB 3

PERANCANGAN DAN IMPLEMENTASI SISTEM

3.1 Pendekatan *Iterative Development* dalam tugas akhir

Proses pengembangan sistem rekomendasi game ini mengadopsi metodologi *Iterative Development*, sebuah pendekatan yang memungkinkan evolusi sistem secara progresif melalui serangkaian siklus berulang. Setiap iterasi, yang mencakup analisis, perancangan, implementasi, dan evaluasi, berfungsi sebagai fondasi untuk penyempurnaan pada siklus berikutnya. Metode ini dipilih karena sangat sesuai dengan karakteristik penelitian yang menggabungkan rekayasa perangkat lunak, pemodelan pengetahuan (ontologi game), dan perancangan algoritma cerdas, sehingga dapat mentransformasi konsep teoritis menjadi aplikasi fungsional yang teruji.

Pada iterasi pertama, fokus utama adalah identifikasi kebutuhan sistem rekomendasi game. Analisis ini mencakup penentuan atribut-atribut krusial sebuah game, seperti genre (misalnya, ActionGame, StrategyGame, RPGGame), platform, developer, dan harga, sebagaimana dimodelkan dalam ontologi. Selain itu, diidentifikasi pula kebutuhan akan sebuah representasi pengetahuan yang dapat diproses mesin untuk mendukung penalaran semantik. Input untuk iterasi ini adalah studi literatur mengenai *information overload* pada platform distribusi digital dan analisis kebutuhan fungsional untuk sebuah sistem rekomendasi game. Berdasarkan analisis tersebut, dirancanglah sebuah ontologi domain game menggunakan editor Protégé. Ontologi ini mendefinisikan Game sebagai kelas induk dengan beberapa subkelas genre. Properti data seperti hasPlatform, hasPrice, dan hasDeveloper juga didefinisikan untuk menangkap atribut-atribut spesifik setiap game [18]. Implementasi awal dilakukan dengan pendekatan semantik murni, di mana aturan SWRL dieksekusi oleh *reasoner* OWL DL standar seperti HermiT. Contoh aturan yang dirancang adalah:

$$\text{Player}(?p) \wedge \text{prefersGenre}(?p, \text{"Strategy"}) \wedge \text{StrategyGame}(?g) \rightarrow \text{recommendedFor}(?g, ?p)$$

Evaluasi pada iterasi pertama mengungkap keterbatasan signifikan *reasoner* formal untuk tugas rekomendasi yang bersifat kuantitatif. *Reasoner* seperti HermiT sangat andal untuk validasi konsistensi ontologi, namun kurang optimal untuk logika skoring. Keluaran dari iterasi ini adalah pemahaman mendalam akan kebutuhan fungsional dan keputusan untuk beralih ke arsitektur yang lebih fleksibel.


Berdasarkan temuan tersebut, pada siklus kedua dirancang sebuah arsitektur *hybrid*. Arsitektur inovatif ini mempertahankan ontologi sebagai model pengetahuan formal, namun menggantikan *reasoner* standar dengan sebuah mesin inferensi kustom yang dibangun menggunakan Python. Tujuannya adalah menggabungkan representasi pengetahuan terstruktur dari ontologi dengan fleksibilitas logika prosedural Python. Implementasi utama pada iterasi kedua adalah pengembangan modul `game_recommender.py`. Modul ini dirancang untuk meniru fungsi *reasoner* dengan mengimplementasikan pilar pertama logika rekomendasi: berbasis aturan (*Rule-Based*). Algoritma skoring menerjemahkan aturan semantik menjadi logika prosedural, di mana setiap game dievaluasi kecocokannya dengan preferensi eksplisit pemain. Bobot skor diterapkan dalam kode, memberikan prioritas pada atribut krusial seperti kecocokan genre. Evaluasi prototipe ini menunjukkan keberhasilan arsitektur *hybrid* dalam menghasilkan rekomendasi dasar yang relevan, namun rekomendasinya masih bersifat statis. Temuan ini menjadi dasar untuk iterasi berikutnya, yaitu kebutuhan untuk mengintegrasikan data historis pemain. Keluaran dari iterasi ini adalah *file* ontologi `game_ontology.owl` yang siap pakai.

Memasuki iterasi ketiga, fokus bergeser untuk mentransformasi sistem menjadi dinamis dan mampu belajar. Dirancanglah perluasan algoritma untuk mengintegrasikan dua pilar tambahan: data riwayat permainan (*play history*) dan popularitas game di kalangan pemain dengan selera serupa. Pada tahap implementasi, modul `game_recommender.py` diperkaya dengan logika untuk menganalisis riwayat permainan dan popularitas berdasarkan data interaksi. Algoritma skoring final kemudian menggabungkan ketiga pilar (preferensi eksplisit, riwayat, dan popularitas) menjadi satu skor relevansi total. Hasilnya adalah sistem yang tidak hanya personal, tetapi juga adaptif terhadap minat pemain

dan mampu menangkap tren komunitas, serta lebih efektif menangani skenario *cold-start*. Pembelajaran dari iterasi ini adalah superioritas pendekatan *multi-modal*, namun kompleksitas yang meningkat menuntut adanya optimasi performa.

Iterasi keempat adalah tahap pematangan sistem. Analisis bergeser pada optimasi performa *backend* dan penyempurnaan pengalaman pengguna (UX). Teridentifikasi adanya *bottleneck* pada *query* basis data dan algoritma skoring. Dari sisi UX, diidentifikasi kebutuhan fitur pendukung seperti *wishlist* interaktif, halaman riwayat permainan, dan saran pencarian dinamis. Implementasi pada siklus final ini mencakup optimasi *query* dan refaktorisasi kode pada *backend*. Di *frontend*, fitur-fitur baru seperti pemberian rating pada riwayat permainan dan saran pencarian diimplementasikan. Penanganan *error* yang lebih *robust* juga ditambahkan untuk meningkatkan stabilitas. Hasil luaran final dari iterasi ini adalah sebuah sistem yang fungsional, stabil, dan siap untuk *deployment*, yang telah berhasil memenuhi semua kebutuhan yang teridentifikasi sepanjang siklus pengembangan.

3.2 Arsitektur Sistem Final



Gambar 3. 1 Arsitektur Sistem Final

Sebagai luaran dari siklus pengembangan iteratif, terbentuklah sebuah arsitektur sistem empat lapis yang dirancang untuk menjawab kebutuhan akan

penalaran logis yang kompleks. Arsitektur ini menginovasi model tiga lapis konvensional dengan menyisipkan sebuah Semantic Layer, yang secara spesifik berfungsi untuk menjembatani representasi pengetahuan formal (ontologi) dengan logika bisnis aplikasi.

3.2.1 *Presentation Layer*

Lapisan Presentasi (*Presentation Layer*) adalah komponen yang berhadapan langsung dengan pengguna dan berfungsi sebagai antarmuka visual dari sistem. Antarmuka ini dibangun sebagai aplikasi web di sisi klien (*client-side*) menggunakan teknologi standar, yaitu HTML5 untuk menstrukturkan konten, CSS3 untuk aspek visual dan tata letak, serta JavaScript untuk fungsionalitas interaktif. Untuk menampilkan data dinamis yang dikirim dari *backend*, seperti daftar rekomendasi game, sistem ini memanfaatkan *engine template* Jinja2.

Selama proses pengembangan iteratif, lapisan ini terus disempurnakan berdasarkan umpan balik untuk mengoptimalkan pengalaman pengguna (UX/UI), termasuk implementasi fitur-fitur seperti filter dinamis dan halaman detail game yang interaktif.

3.2.2 *Application Layer*

Lapisan Aplikasi (*Application Layer*) merupakan inti dari *backend* sistem, dibangun menggunakan *microframework* Flask dan berfungsi sebagai orkestrator seluruh logika bisnis. Komponen utamanya meliputi:

- Manajemen Rute (*Route Management*): Menangani permintaan HTTP yang masuk ke berbagai *endpoint* seperti /dashboard, /profile, /wishlist, dan /recommendations.
- Autentikasi & Manajemen Sesi: Mengelola validasi identitas pemain dan menjaga kontinuitas sesi selama interaksi.
- Validasi Data: Memastikan semua input dari pemain valid dan aman sebelum diteruskan untuk diproses oleh lapisan semantik.

- Pemformatan Respons: Menstrukturkan data hasil rekomendasi dari lapisan semantik agar siap ditampilkan oleh Lapisan Presentasi.

Seiring berjalannya proses pengembangan iteratif, lapisan ini terus berkembang dengan penambahan *endpoint* baru, peningkatan penanganan *error* (*error handling*), dan optimasi manajemen sesi berdasarkan kebutuhan yang teridentifikasi.

3.2.3 *Semantic Layer* - Inovasi Utama

Lapisan Semantik (*Semantic Layer*) adalah inovasi inti dalam penelitian ini, yang implementasinya terpusat pada modul `game_recommender.py`. Lapisan ini berperan sebagai ‘otak’ dari sistem yang menjalankan proses penalaran (*reasoning*) *hybrid*, dengan mengombinasikan pendekatan berbasis pengetahuan formal dan logika prosedural.

Evolusi Implementasi:

- Iterasi 1-2: Peralihan dari *Reasoner* Formal. Desain awal sistem menggunakan *reasoner* OWL DL standar untuk inferensi. Namun, pendekatan ini kemudian berevolusi menjadi sebuah implementasi kustom (Python) yang mensimulasikan fungsi *reasoner*, namun dengan algoritma yang dirancang khusus untuk tugas rekomendasi kuantitatif.
- Iterasi 3-4: Integrasi Multi-Pilar. Pengembangan dilanjutkan dengan merancang algoritma *hybrid* yang mengintegrasikan tiga pilar rekomendasi (preferensi eksplisit, riwayat interaksi, dan popularitas komunitas) ke dalam satu sistem skoring dengan bobot yang dapat dikonfigurasi.

Komponen Utama *Semantic Layer*:

- Pemuat Ontologi (*Ontology Loader*): Bertanggung jawab untuk memuat dan mem-parsing *file* ontologi game .owl ke dalam memori sebagai model pengetahuan.
- Pemeta Semantik (*Semantic Mapper*): Berfungsi untuk memetakan data dari lapisan aplikasi (misalnya, input preferensi pemain) ke dalam konsep dan individu yang sesuai di dalam ontologi.

- Mesin Penalaran Hibrida (*Hybrid Reasoning Engine*): Mengeksekusi algoritma skoring multi-pilar yang telah dirancang untuk menghitung skor relevansi setiap game.
- Penghasil Rekomendasi (*Recommendation Generator*): Mengumpulkan hasil dari *engine* penalaran, kemudian menyusun dan mengurutkan daftar game yang akan direkomendasikan berdasarkan skor akhir.

3.2.4 *Data Layer*

Lapisan Data (*Data Layer*) bertanggung jawab atas penyimpanan data persisten, diimplementasikan menggunakan SQLite sebagai *Database Management System* (DBMS) dan Flask-SQLAlchemy sebagai *Object-Relational Mapper* (ORM). Seiring dengan pengembangan iteratif, struktur tabel basis data berevolusi untuk mendukung fitur-fitur yang semakin kompleks:

1. Profil Pemain (*Player Profiles*): Menyimpan informasi dasar dan preferensi eksplisit dari setiap pemain.
2. Katalog Game (*Game Catalog*): Berisi daftar game beserta atribut-atributnya yang telah dipetakan sesuai dengan model ontologi.
3. Riwayat Pencarian (*Search History*): Mencatat kata kunci atau filter yang digunakan pemain, menjadi salah satu pilar untuk rekomendasi dinamis.
4. Riwayat Interaksi (*Interaction History*): Menyimpan data historis seperti game yang dimainkan atau diberi rating, yang menjadi dasar untuk pilar rekomendasi berbasis popularitas dan perilaku.

3.3 Perancangan Fungsional Sistem

Sebelum masuk ke detail arsitektur teknis, dilakukan perancangan fungsional untuk mendefinisikan alur interaksi antara pemain (*player*) dan sistem. Perancangan ini divisualisasikan menggunakan *Use Case Diagram* untuk menggambarkan fungsionalitas utama, dan *Activity Diagram* untuk merinci langkah-langkah dalam setiap skenario penggunaan. Kedua diagram tersebut dirancang berdasarkan analisis kebutuhan, dengan mengidentifikasi dua aktor utama yang terlibat: Pemain (baik pengunjung anonim maupun yang terdaftar) dan

Sistem itu sendiri. Pendekatan ini memastikan bahwa perilaku dan fungsionalitas sistem telah terpetakan dengan jelas sebelum tahap implementasi teknis dimulai.

3.3.1 Functional Requirement

Tabel 3. 1 Functional Requirement

ID	Deskripsi Kebutuhan
Manajemen Akun Pemain	
FR01	Sistem harus menyediakan fungsionalitas bagi pemain baru untuk membuat akun, termasuk pengisian data profil dan preferensi awal (misalnya, genre favorit, platform).
FR02	Sistem harus menyediakan fungsionalitas login bagi pemain terdaftar dan fungsionalitas logout untuk keluar dari sesi.
FR03	Pemain yang telah login harus dapat mengakses halaman profil untuk melihat dan mengelola data serta preferensi mereka.
Katalog dan Pencarian Game	
FR04	Sistem harus dapat menampilkan keseluruhan katalog game yang tersedia, lengkap dengan halaman detail untuk setiap game.
FR05	Pemain harus dapat melakukan pencarian game berdasarkan kata kunci melalui fitur pencarian.
FR06	Sistem harus menampilkan saran pencarian dinamis yang relevan, yang dapat didasarkan pada riwayat interaksi dan pencarian terakhir pemain.
Sistem Rekomendasi	
FR07	Sistem harus menampilkan daftar rekomendasi game yang telah dipersonalisasi di halaman utama bagi pemain yang telah login.


ID	Deskripsi Kebutuhan
FR08	Algoritma rekomendasi harus menggunakan preferensi awal pemain (misalnya, genre dan platform favorit) sebagai dasar skoring (Pilar 1: <i>Rules-Based</i>).
FR09	Algoritma rekomendasi harus mampu menyesuaikan skor relevansi berdasarkan riwayat pencarian pemain (Pilar 2: Dinamis).
FR10	Algoritma rekomendasi harus memperkuat skor berdasarkan data interaksi (misalnya, game yang dimainkan dan rating) dari pemain lain dengan selera serupa (Pilar 3: Popularitas/Kolaboratif).
Fungsionalitas Interaksi	
FR11	Pemain yang telah login harus dapat menambah dan menghapus game dari daftar keinginan (<i>wishlist</i>) mereka.
FR12	Pemain harus dapat mengakses halaman daftar keinginan (<i>wishlist</i>) untuk melihat semua game yang telah mereka simpan.
FR13	Pemain harus dapat menandai game di dalam wishlist sebagai ‘sudah dimiliki’ atau ‘sudah dimainkan’.
Fitur Riwayat dan Ulasan	
FR14	Pemain yang telah login harus dapat mengakses halaman riwayat interaksi dari menu profil mereka.
FR15	Pemain harus dapat melihat seluruh riwayat game yang pernah dimainkan atau ditandai sebagai ‘dimiliki’.
FR16	Pemain harus dapat memberikan rating bintang (1-5) untuk setiap game yang ada di dalam riwayat interaksinya.

Kebutuhan fungsional yang dirinci pada Tabel 3.1 dirancang secara menyeluruh untuk membangun sebuah pengalaman rekomendasi game yang cerdas dan lengkap, mulai dari interaksi awal pemain hingga aktivitas pasca-rekomendasi. Fondasi dari sistem ini adalah manajemen akun pemain yang solid, di mana pemain dapat mendaftar sambil menyertakan preferensi awal mereka, melakukan login untuk autentikasi, dan mengakses halaman profil. Di atas fondasi tersebut, dibangun fungsionalitas inti untuk penemuan konten, yang memungkinkan pemain menjelajahi katalog game atau melakukan pencarian spesifik, yang diperkuat oleh fitur saran pencarian dinamis untuk mempercepat proses eksplorasi.

Inti dari kecerdasan sistem ini terletak pada mesin rekomendasinya, yang diwajibkan untuk menyajikan daftar game yang dipersonalisasi di halaman utama. Algoritma hibrida yang dirancang bekerja dengan mengombinasikan tiga pilar utama. Pertama, memanfaatkan preferensi awal pemain sebagai dasar skoring. Kedua, menyesuaikan skor secara dinamis berdasarkan riwayat pencarian, dan ketiga, memperkuat relevansi dengan menganalisis riwayat interaksi dan rating dari pemain lain dengan selera serupa.

Untuk mendukung interaksi pemain, sistem dilengkapi dengan fungsionalitas pendukung seperti daftar keinginan (*wishlist*). Pemain yang terdaftar dapat menambah, melihat, dan mengelola game di dalam *wishlist* mereka. Interaksi pemain tidak berhenti di situ; sistem juga menyediakan fitur riwayat dan ulasan yang krusial. Pemain dapat mengakses halaman riwayat interaksi untuk melihat semua game yang pernah mereka mainkan atau tandai. Di halaman ini, mereka dapat memberikan rating bintang, yang menjadi komponen vital dalam siklus umpan balik (*feedback loop*). Fungsionalitas rating ini secara aktif memanfaatkan masukan dari pemain untuk terus-menerus menyempurnakan akurasi rekomendasi bagi seluruh komunitas.

3.3.2 Use Case Diagram



Gambar 3. 2 Use Case Diagram

Pemodelan interaksi antara pemain dan fungsionalitas sistem direpresentasikan secara formal menggunakan *Use Case Diagram*. Diagram ini berperan sebagai cetak biru fungsional yang memetakan fitur-fitur utama sistem dan bagaimana aktor dapat berinteraksi dengannya. Penggunaan diagram ini pada tahap perancangan sangat krusial untuk memastikan semua kebutuhan fungsional yang teridentifikasi dapat diakomodasi oleh sistem.

Dalam konteks sistem rekomendasi game ini, teridentifikasi dua aktor utama: Pemain, yang dapat berupa pengunjung anonim atau pengguna terdaftar, dan Admin sebagai pengelola data sistem. Gambar 3.2 mengilustrasikan berbagai kasus penggunaan yang tersedia bagi setiap aktor, serta menyoroti dependensi antar fungsionalitas, seperti keharusan login sebelum dapat mengakses fitur-fitur yang dipersonalisasi. Berikut adalah rincian dari setiap kasus penggunaan tersebut:

1. Mengelola Akun

a. Aktor: Pemain

- b. Deskripsi: Kasus penggunaan ini mencakup seluruh fungsionalitas terkait manajemen akun. Alur dimulai ketika pengunjung mendaftar

sebagai pemain baru dengan mengisi data profil dan preferensi game (misalnya, genre atau platform favorit). Pemain yang sudah terdaftar dapat melakukan login untuk mengakses fitur personal dan logout untuk mengakhiri sesi.

2. Melihat Game & Detail

- a. Aktor: Pemain, Admin
- b. Deskripsi: Merupakan fungsionalitas inti yang memungkinkan aktor untuk menelusuri katalog game. Pemain dapat menjelajahi seluruh daftar game atau membuka halaman detail untuk melihat informasi yang lebih spesifik. Admin juga memiliki akses untuk melihat data game.

3. Mencari Game

- a. Aktor: Pemain
- b. Deskripsi: Pemain dapat menggunakan fitur pencarian untuk menemukan game berdasarkan kata kunci. Jika pemain sedang dalam sesi login, aktivitas pencariannya akan dicatat untuk membantu personalisasi rekomendasi di masa depan.

4. Mengelola Wishlist

- a. Aktor: Pemain Terdaftar
- b. Deskripsi: Kasus penggunaan ini hanya dapat diakses oleh pemain yang telah login. Pemain dapat menambahkan game ke dalam daftar keinginan (*wishlist*) mereka atau menghapusnya.


5. Melihat Riwayat Interaksi

- a. Aktor: Pemain Terdaftar
- b. Deskripsi: Pemain yang telah login dapat mengakses halaman profil untuk melihat riwayat interaksi mereka, seperti daftar game yang pernah dimainkan atau diberi rating.

6. Melihat Rekomendasi Personal

- a. Aktor: Pemain Terdaftar
- b. Deskripsi: Merupakan fitur cerdas utama sistem. Ketika seorang pemain yang telah login mengakses halaman utama, sistem akan menjalankan mesin inferensi untuk menyajikan daftar game yang direkomendasikan secara personal untuknya.

3.3.3 Activity Diagram Rekomendasi Produk




Gambar 3. 3 Rekomendasi Produk

Gambar 3.3 menggambarkan alur proses rekomendasi produk yang melibatkan interaksi antara pengguna dan sistem. Proses dimulai ketika pengguna membuka halaman utama aplikasi. Setelah itu, sistem menerima permintaan dari pengguna dan menjalankan logika rekomendasi. Logika ini mencakup analisis terhadap profil dan menjalankan logika rekomendasi. Logika ini mencakup analisis terhadap profil

pengguna, riwayat pembelian, serta data interaksi sebelumnya. Berdasarkan analisis tersebut, sistem menghitung skor masing-masing produk dan mengurutkannya, lalu memilih delapan produk teratas yang paling relevan. Produk-produk yang telah direkomendasikan tersebut kemudian ditampilkan kepada pengguna dalam bentuk daftar, dan proses rekomendasi pun selesai. Alur ini dirancang untuk memberikan pengalaman personalisasi yang lebih baik bagi pengguna berdasarkan data historis dan preferensi mereka.

3.3.4 Activity Diagram Daftar Akun




Gambar 3. 4 Daftar Akun

Gambar 3.4 merinci alur kerja bagi seorang pemain baru saat membuat akun, sebuah proses yang mencakup pengumpulan data preferensi awal untuk sistem rekomendasi. Proses interaksi dimulai ketika seorang pengunjung memilih opsi “Registrasi”, yang kemudian akan direspons oleh sistem dengan menyajikan sebuah formulir pendaftaran. Pemain diwajibkan untuk melengkapi seluruh kolom

pada formulir, yang terdiri dari data kredensial (seperti nama pengguna, email, dan *password*) serta data preferensi personal yang menjadi fondasi rekomendasi, yaitu genre favorit, platform yang dimiliki, dan mekanisme permainan yang disukai.

Setelah formulir dikirim, sistem akan menjalankan prosedur validasi data. Apabila terdapat input yang tidak valid atau kurang lengkap, formulir akan ditampilkan kembali beserta notifikasi kesalahan yang spesifik. Sebaliknya, jika seluruh data telah tervalidasi, informasi pemain baru tersebut akan disimpan ke dalam tabel Pemain di basis data. Sebagai langkah terakhir, sistem secara otomatis akan mengarahkan pemain ke halaman login untuk memulai sesi autentikasi pertama mereka.

3.3.5 Activity Diagram Login Akun




Gambar 3. 5 Login Akun

Gambar 3.5 mengilustrasikan alur autentikasi untuk seorang pemain yang telah terdaftar, dimulai dari saat mereka mengakses halaman login. Proses diawali ketika pemain memasukkan kredensial berupa email dan *password*, kemudian mengirimkannya dengan menekan tombol “Login”. Informasi ini selanjutnya diterima oleh sistem untuk memulai prosedur verifikasi dengan mencocokkannya terhadap data yang tersimpan di basis data.

Terdapat dua kemungkinan hasil dari validasi ini. Jika kredensial terbukti valid, sistem akan membuat sebuah sesi (*session*) unik untuk pemain tersebut sebagai penanda autentikasi yang berhasil. Setelah itu, pemain akan diarahkan ke halaman utama, yang kini akan menampilkan konten yang dipersonalisasi, termasuk sapaan dan daftar rekomendasi game yang relevan. Namun, jika validasi gagal, sistem akan menolak akses dan menampilkan kembali halaman login, disertai dengan pesan notifikasi kesalahan.

3.3.6 Activity Diagram Pencarian Produk




Gambar 3. 6 Pencarian Produk

Gambar 3.6 merinci fungsionalitas pencarian yang memungkinkan pemain untuk menemukan game secara spesifik. Proses ini diawali saat pemain memasukkan satu atau lebih kata kunci (contohnya, “RPG open world”) ke dalam kolom pencarian (*search bar*) yang tersedia dan mengonfirmasinya dengan menekan tombol “Cari”. Input tersebut kemudian diterima oleh sistem untuk diproses sebagai sebuah kueri pencarian.

Apabila pemain melakukan pencarian saat sedang *login*, kata kunci yang digunakan akan disimpan ke dalam tabel SearchHistory yang terhubung dengan ID pemain tersebut; langkah ini bertujuan untuk merekam minat pemain secara dinamis. Selanjutnya, sistem akan mengeksekusi kueri ke basis data Game untuk menyaring semua entri yang judul, genre, atau tag-nya cocok dengan kata kunci. Daftar game yang relevan dari hasil kueri tersebut kemudian disajikan kepada pemain pada halaman hasil pencarian.

3.3.7 Activity Diagram Belanja Utama




Gambar 3. 7 Alur Belanja Utama

Gambar 3.7 mengilustrasikan alur interaksi utama pemain dengan katalog game. Saat seorang pemain yang telah *login* menjelajahi halaman utama atau katalog game, mereka akan menemukan serangkaian kartu game. Ketika menemukan game yang menarik, pemain dapat menekan tombol “Tambah ke Wishlist”. Aksi ini memicu pengiriman permintaan ke sistem, yang kemudian akan mencatat ID game tersebut ke dalam data wishlist yang terasosiasi dengan sesi pemain.

Setelah game berhasil ditambahkan, sistem akan memberikan umpan balik visual secara langsung kepada pemain. Hal ini dilakukan dengan memperbarui ikon wishlist (biasanya di bagian *header*) untuk mengindikasikan bahwa sebuah item baru telah berhasil disimpan, sehingga pemain mendapatkan konfirmasi instan atas tindakan mereka.


3.3.8 Activity Diagram Pengelolaan Keranjang Belanja



Gambar 3. 8 Alur Pengelolaan Keranjang

Gambar 3.8 merinci alur bagi pemain untuk mengelola konten daftar keinginan (*wishlist*) mereka. Proses ini dimulai ketika pemain mengakses halaman Wishlist. Sistem akan merespons dengan membaca data dari sesi (*session*) pemain dan menampilkan semua game yang telah disimpan sebelumnya, lengkap dengan detailnya seperti gambar sampul dan judul. Pada halaman ini, pemain dapat berinteraksi dengan daftar tersebut, di mana aksi utamanya adalah menekan tombol “Hapus” untuk menghilangkan sebuah game dari wishlist. Setiap aksi ini akan memicu permintaan ke sistem, yang kemudian akan memperbarui data di dalam sesi. Setelah pembaruan berhasil, sistem akan memuat ulang halaman wishlist untuk menampilkan kondisi terkini, sehingga pemain dapat melihat bahwa game tersebut telah berhasil dihilangkan dari daftar.

3.3.9 Activity Diagram Alur Proses Checkout




Gambar 3. 9 Alur Proses Checkout

Diagram 3.9 mengilustrasikan proses finalisasi interaksi, di mana seorang pemain mengonfirmasi bahwa mereka telah memainkan atau memiliki sebuah game. Alur ini dapat dimulai dari halaman *wishlist* atau halaman detail game, ketika pemain menekan tombol seperti “Tandai Sudah Dimainkan”. Sistem akan merespons dengan memvalidasi aksi tersebut, kemudian mengeksekusi beberapa pembaruan penting di basis data: membuat catatan interaksi baru di tabel *InteractionHistory* yang menautkan pemain dengan game tersebut, dan secara opsional menghapus game itu dari *wishlist*. Setelah data interaksi berhasil disimpan, sistem akan mengarahkan pemain ke halaman “Riwayat Interaksi” miliknya. Halaman ini berfungsi sebagai konfirmasi bahwa aktivitas mereka telah berhasil

dicatat dan kini menjadi bagian dari profil historis mereka untuk digunakan dalam penyempurnaan rekomendasi di masa depan.

3.3.10 Entity Relationship Diagram

Setelah alur kerja fungsional dipetakan melalui *activity diagram*, langkah perancangan selanjutnya adalah mendefinisikan struktur basis data yang akan mendukung logika mesin rekomendasi. *Entity-Relationship Diagram* (ERD) yang disajikan pada Gambar 3.10 dirancang secara konseptual untuk tujuan ini. Diagram tersebut memvisualisasikan bagaimana berbagai entitas data mulai dari profil statis pemain hingga data interaksi dinamis mereka (seperti riwayat permainan dan pencarian) saling terhubung dan berfungsi sebagai input vital bagi Mesin Skoring (*SCORING_ENGINE*) yang menjadi inti dari logika rekomendasi.



Gambar 3. 10 ERD Pengaruh Data Pengguna terhadap Sistem Skoring

Diagram ERD tersebut menyoroti tiga entitas basis data utama yang menjadi bahan bagi algoritma rekomendasi *hybrid* yang dikembangkan:

- Entitas PEMAIN (*PLAYER*) sebagai Fondasi Personalisasi (Pilar 1)

Entitas PEMAIN menyimpan atribut-atribut preferensi eksplisit yang didefinisikan oleh pemain saat registrasi, seperti *preferred_genre*, *owned_platform*, dan *preferred_mechanic*. Data ini menjadi fondasi dari personalisasi dan merupakan input utama untuk Pilar 1 (rekomendasi berbasis aturan). Mesin skoring memanfaatkan data ini untuk melakukan pencocokan langsung antara fitur game dengan profil pemain, memberikan skor dasar yang tinggi pada game yang secara semantik relevan dengan preferensi inti pemain.

- Entitas RIWAYAT PENCARIAN (*SEARCH_HISTORY*) sebagai Cerminan Minat Dinamis (Pilar 2)

Entitas RIWAYAT PENCARIAN berfungsi untuk merekam jejak minat pemain yang bersifat dinamis. Setiap kata kunci yang dicari oleh pemain yang *login* akan disimpan dan ditautkan ke ID mereka. Data kata kunci (*search_term*) ini kemudian menjadi input krusial bagi Pilar 2. Mesin skoring menganalisis frekuensi kemunculan setiap kata kunci untuk memberikan bobot tambahan pada minat pemain, memungkinkan sistem untuk beradaptasi secara *real-time* terhadap apa yang sedang aktif dicari oleh pemain.

- Entitas RIWAYAT INTERAKSI (*INTERACTION_HISTORY*) sebagai Bukti Sosial dan Kualitas (Pilar 3)

Entitas RIWAYAT INTERAKSI memainkan peran ganda sebagai input untuk Pilar 3. Pertama, data game yang pernah dimainkan (*played_game*) digunakan oleh mesin skoring untuk mengidentifikasi sekelompok pemain lain dengan selera serupa. Kedua, di dalam kelompok tersebut, sistem menganalisis data interaksi dan rating. Jumlah pemain yang memainkan sebuah game digunakan sebagai indikator popularitas, sementara rata-rata rating digunakan sebagai proksi kualitas. Mesin skoring mengombinasikan kedua metrik ini untuk memberikan skor bonus pada

game yang tidak hanya populer, tetapi juga terbukti memuaskan komunitas pemain.

Secara keseluruhan, desain basis data ini dirancang agar terintegrasi secara inheren dengan arsitektur algoritma rekomendasi. Setiap data, baik profil statis maupun interaksi dinamis pemain, tidak hanya disimpan sebagai catatan, tetapi juga secara aktif berkontribusi pada kalkulasi skor akhir. Hal ini pada akhirnya menghasilkan sebuah daftar rekomendasi yang personal, adaptif, dan relevan secara sosial.

3.4 Pemodelan Pengetahuan: Ontologi Game

3.4.1 Evolusi Ontologi Melalui Iterasi

Model ontologi game dalam penelitian ini mengalami evolusi secara signifikan seiring berjalannya siklus pengembangan iteratif. Proses ini mengubah ontologi dari sebuah konsep awal yang sederhana menjadi model pengetahuan yang kaya dan mampu mendukung proses penalaran (*reasoning*) yang kompleks.

1. Iterasi 1: Perancangan Struktur Dasar. Pada tahap awal, ontologi dirancang dengan mendefinisikan konsep-konsep fundamental, yaitu kelas Game dan Player, beserta beberapa properti data dasar seperti `hasPlatform` dan `hasDeveloper`.
2. Iterasi 2-3: Ekspansi Hierarki dan Relasi. Ontologi kemudian diperluas dengan mengembangkan hierarki kelas yang lebih terperinci, yaitu dengan menambahkan subkelas genre seperti `ActionGame`, `StrategyGame`, dan `RPGGame`. Pada tahap ini, properti objek utama seperti `recommendedFor` dan `preferredBy` juga ditambahkan untuk mendefinisikan relasi antara game dan pemain.
3. Iterasi 4: Optimasi dan Pengisian Data. Siklus terakhir berfokus pada pematangan model ontologi. Aktivitas utama meliputi penyempurnaan batasan-batasan (*constraints*) pada properti, pengisian data *individu* (contoh-contoh game) ke dalam ontologi, serta validasi akhir untuk memastikan konsistensi logis dari keseluruhan model.

3.4.2 Struktur Final Ontologi

Ontologi final yang dikembangkan mendefinisikan sebuah struktur hierarkis yang terperinci. Kelas Game ditetapkan sebagai konsep akar, dengan tiga subkelas utama yang merepresentasikan genre, yaitu ActionGame, StrategyGame, dan RPGGame. Struktur taksonomis ini memungkinkan *reasoner* untuk memahami, misalnya, bahwa sebuah *individu* yang diklasifikasikan sebagai ActionGame juga merupakan anggota dari kelas Game.

Berikut ini adalah definisi properti data dengan batasan (*constraint*) yang diterapkan:

- hasPlatform: Domain Game, Range xsd:string, *Functional Property*
- hasDeveloper: Domain Game, Range xsd:string, *Functional Property*
- hasPrice: Domain Game, Range xsd:decimal, *Functional Property*
- hasPlaytime: Domain Game, Range xsd:integer, *Functional Property*
- hasGraphics: Domain Game, Range xsd:string, *Functional Property*
- Properti Objek dan Relasi Antar Entitas

Berikut adalah definisi relasi yang menghubungkan antar-individu dalam ontologi:

- recommendedFor: Domain Game, Range Player
- preferredBy: Domain Player, Range Game, *Inverse of recommendedFor*

3.4.3 Instance Data dan Validasi

Untuk menguji dan memvalidasi model, ontologi ini diisi dengan data *individu* (*instance*) yang representatif untuk setiap genre game. Berikut adalah contoh salah satu *individu*:

StrategyGame1:

- Tipe: StrategyGame
- hasPlaytime: 60
- hasPlatform: "PC"
- hasGraphics: "2D"
- hasPrice: 120000.0
- hasDeveloper: "Paradox"

3.5 Integrasi Sistem dan *Deployment*

3.5.1 Evolusi dari Konsep Formal ke Implementasi Praktis

Mesin inferensi, yang merupakan inti dari logika sistem, mengalami evolusi signifikan selama proses pengembangan. Pendekatan awal yang mengandalkan *reasoner* formal murni kemudian ditransformasikan menjadi sebuah implementasi *hybrid* yang lebih pragmatis, namun tetap berpegang pada prinsip-prinsip penalaran semantik.

1. Iterasi 1: Pendekatan Berbasis Aturan SWRL Murni. Desain awal sistem sepenuhnya bergantung pada aturan SWRL (*Semantic Web Rule Language*) yang dieksekusi oleh *reasoner* OWL DL seperti HermiT. Aturan-aturan ini dirancang untuk mengekspresikan logika rekomendasi secara formal, contohnya:
 - $\text{Player}(?p) \wedge \text{prefersGenre}(?p, \text{"RPG"}) \wedge \text{RPGGame}(?g) \rightarrow \text{recommendedFor}(?g, ?p)$
 - $\text{Player}(?p) \wedge \text{ownsPlatform}(?p, ?platform) \wedge \text{Game}(?g) \wedge \text{hasPlatform}(?g, ?platform) \rightarrow \text{recommendedFor}(?g, ?p)$
2. Iterasi 2: Identifikasi Keterbatasan. Hasil evaluasi dari pendekatan murni ini menunjukkan beberapa keterbatasan inheren dari *reasoner* formal ketika diterapkan untuk tugas rekomendasi, antara lain:
 - a. Kesulitan dalam menangani penalaran kuantitatif dan pembobotan skor yang dinamis.

- b. Keterbatasan dalam mengintegrasikan berbagai sumber bukti (misalnya, preferensi eksplisit dan data historis).
 - c. Kurang optimal dari sisi performa untuk aplikasi yang membutuhkan respons *real-time*.
 - d. Tidak dirancang untuk menangani ketidakpastian atau penalaran probabilistik.
3. Iterasi 3-4: Implementasi Mesin Inferensi Hibrida. Berdasarkan keterbatasan tersebut, pengembangan beralih ke pembuatan mesin inferensi kustom. Mesin ini mensimulasikan peran fungsional dari *reasoner* formal, namun menggunakan algoritma prosedural (Python) yang secara spesifik dirancang untuk kebutuhan sistem rekomendasi game.

3.5.2 Arsitektur Algoritma Hybrid

Implementasi final dari mesin inferensi hibrida, yang terkandung dalam modul `game_recommender.py`, mengadopsi sebuah pendekatan skoring multi-pilar. Pendekatan ini secara efektif mengombinasikan logika dari pendekatan *rules-based*, *content-based*, dan *collaborative filtering*.

Algoritma Skoring Multi-Pilar:

```
def get_recommendations(player_profile, all_games):
```

```
    """
```

```
    Implementasi mesin inferensi hibrida yang mensimulasikan
```

```
    fungsionalitas reasoner dengan algoritma skoring yang dirancang
```

```
    khusus untuk rekomendasi game.
```

```
    """
```

Implementasi final dalam penelitian ini mengadopsi sebuah pendekatan skoring yang mengintegrasikan tiga pilar utama yang telah dibahas. Algoritma ini secara fungsional mensimulasikan peran sebuah *reasoner* dengan cara mengevaluasi setiap game (g) dalam katalog terhadap profil pemain (p). Proses skoring untuk setiap game ini dapat diformulasikan sebagai berikut:

$$S_{\text{total}}(u, p) = S_{\text{pref}}(u, p) + S_{\text{search}}(u, p) + S_{\text{social}}(u, p)$$

Dimana:

- $S_{\text{total}}(u, p)$ adalah skor relevansi total dari produk p untuk pengguna u .
- $S_{\text{pref}}(u, p)$ adalah skor dari pilar Preferensi Awal (Rules-Based).
- $S_{\text{search}}(u, p)$ adalah skor dari pilar Riwayat Pencarian (Content-Based).
- $S_{\text{social}}(u, p)$ adalah skor dari pilar Rekomendasi Sosial (Collaborative-Based).

Berikut adalah rincian formulasi untuk setiap pilar:

3.5.3 Pilar Pertama: *Rules-Based*

Pilar pertama ini merupakan implementasi dari rekomendasi berbasis aturan (*Rules-Based*), di mana pengetahuan dari ontologi game diterjemahkan ke dalam logika prosedural. Sistem akan mengevaluasi kecocokan antara atribut setiap game dengan preferensi eksplisit yang telah didefinisikan oleh pemain.

Implementasi aturan berbasis pengetahuan untuk game

```
if game.genre and pref_genre and game.genre.capitalize() ==
pref_genre.capitalize():
```

```
    score += 5 # Genre adalah faktor paling krusial
```

```
if game.platform and owned_platform and game.platform.capitalize() ==
owned_platform.capitalize():
```

```
    score += 4 # Kesesuaian platform yang dimiliki pemain
```

```
if game.mechanic and pref_mechanic and game.mechanic.capitalize() ==
pref_mechanic.capitalize():
```

```
    score += 2 # Kecocokan mekanisme permainan
```

Implementasi ini menerjemahkan aturan semantik formal ke dalam logika prosedural yang dapat dioptimasi untuk performa. Pilar ini merepresentasikan implementasi dari pengetahuan ontologi dalam bentuk aturan prosedural. Sistem

mengevaluasi kecocokan atribut produk dengan preferensi eksplisit pengguna melalui penjumlahan berbobot:

$$S_{\text{pref}}(u, p) = \sum_{f \in F_{\text{pref}}} w_f \cdot M_f(u, p)$$

Dimana:

- F_{pref} adalah himpunan fitur preferensi, yaitu ukuran, gaya, gender.
- w_f adalah bobot kepentingan yang telah ditentukan: $w_{\text{genre}} = 5$, $w_{\text{platform}} = 4$, $w_{\text{mechanic}} = 2$.
- $M_f(u, p)$ adalah fungsi *match* yang bernilai 1 jika preferensi pengguna u untuk fitur f cocok dengan atribut produk p , dan 0 jika tidak.

3.5.4 Pilar Kedua: *History Pencarian*

Pilar kedua ini memberikan kemampuan adaptif pada sistem dengan menganalisis perilaku dinamis pemain. Berbeda dengan preferensi awal yang cenderung statis, minat seorang pemain dapat berubah seiring waktu. Oleh karena itu, sistem rekomendasi yang cerdas harus mampu menangkap tidak hanya profil jangka panjang pemain, tetapi juga minat sesaat mereka yang tercermin dari aktivitas pencarian.

Analisis riwayat pencarian untuk pilar dinamis

all_searches =

db.session.query(SearchHistory.term).filter_by(player_id=player.id).all()

search_keyword_counts = Counter([s.term.lower() for s in all_searches])

Penambahan skor berdasarkan kecocokan kata kunci

for keyword, count in search_keyword_counts.items():

if (keyword in game.title.lower() or

(game.description and keyword in game.description.lower()) or

(game.genre and keyword in game.genre.lower())):

Bobot skor ditambah berdasarkan frekuensi pencarian

$score += count$

Logika ini memungkinkan sistem untuk memberikan bobot lebih pada game yang cocok dengan apa yang sedang aktif dicari oleh pemain. Semakin sering sebuah kata kunci dicari, semakin besar pula pengaruhnya terhadap skor rekomendasi, sehingga hasilnya menjadi lebih dinamis dan relevan dengan minat pemain saat itu. Implementasi ini memungkinkan sistem untuk merespons perubahan preferensi pengguna berdasarkan pola pencarian terbaru. Pilar ini memberikan kemampuan adaptasi sistem terhadap perilaku pengguna dinamis. Skor bonus dihitung berdasarkan frekuensi kemunculan kata kunci yang relevan:

$$S_{search}(u, p) = \sum_{k \in K_u} Freq(k) \cdot Match(k, p)$$

Dimana:

- K_u adalah himpunan semua kata kunci pencarian unik yang pernah dilakukan oleh pengguna u .
- $Freq(k)$ adalah frekuensi (jumlah kemunculan) kata kunci k dalam seluruh riwayat pencarian pengguna u .
- $Match(k, p)$ adalah fungsi match yang bernilai 1 jika kata kunci k ditemukan dalam atribut teks produk p (nama, kategori, atau deskripsi), dan 0 jika tidak.

3.5.5 Pilar Ketiga: *Riwayat Pembelian*

Pilar ketiga mengintegrasikan konsep bukti sosial (*social proof*) dengan memanfaatkan ‘kebijaksanaan komunitas’ (*communal wisdom*). Jika dua pilar sebelumnya berfokus pada interaksi individual, pilar ini memperluas cakupan dengan asumsi bahwa seorang pemain cenderung akan menyukai game yang juga populer di kalangan pemain lain dengan selera serupa. Dengan menganalisis riwayat interaksi dan rating dari sekelompok pemain yang memiliki preferensi genre yang sama, sistem dapat mengidentifikasi tren serta game berkualitas yang sedang diminati oleh komunitas.

```

# Analisis tren komunitas berdasarkan jumlah pemain

similar_player_interactions = db.session.query(

    InteractionHistory.game_id,

    func.count(InteractionHistory.player_id).label('total_players')

).filter(

    InteractionHistory.played_genre == pref_genre,

    InteractionHistory.player_id != player.id

).group_by(InteractionHistory.game_id).all()

# Penambahan skor berdasarkan popularitas game di komunitas

if game.id in popular_games_by_players:

    social_bonus = popular_games_by_players[game.id]

    score += social_bonus

```

Dengan demikian, pilar ini memberikan dimensi sosial pada rekomendasi. Game yang tidak hanya cocok secara atributif dengan profil pemain, tetapi juga terbukti populer dan berkualitas tinggi di antara komunitas dengan selera serupa, akan mendapatkan peningkatan skor yang signifikan. Implementasi ini memungkinkan sistem untuk mengidentifikasi produk populer di antara pengguna dengan preferensi serupa. Pilar ini mengintegrasikan *social proof* dan *collaborative filtering* dengan menganalisis tren pembelian dari pengguna lain yang selernya serupa.

$$S_{\text{social}}(u, p) = (Q(p, U_{\text{similar}}) \cdot w_{\text{social}}) + R_{\text{avg}}$$

Di mana:

- U_{similar} adalah sekelompok pengguna lain yang memiliki preferensi genre yang sama dengan pengguna u .
- $Q(p, U_{\text{similar}})$ adalah total kuantitas pembelian produk p oleh semua pengguna dalam kelompok U_{similar} .

- w_{social} adalah bobot pengali untuk setiap game yang terjual. Dalam implementasi, $w_{\text{social}} = 2$.
- R_{avg} adalah rata-rata rating yang diberikan untuk produk.

3.6 Integrasi Sistem dan *Deployment*

3.6.1 Integrasi Antar Komponen

Proses integrasi antar lapisan sistem disempurnakan secara bertahap melalui siklus iteratif untuk menjamin alur komunikasi data yang lancar dan efisien:

1. Desain API Internal: Sebuah *Application Programming Interface* (API) internal yang terstruktur dirancang untuk menjadi jembatan komunikasi antar lapisan, memfasilitasi pengembangan yang modular dan pengujian yang terisolasi.
2. Penanganan Kesalahan (*Error Handling*): Mekanisme penanganan kesalahan yang komprehensif diimplementasikan untuk mengelola skenario tak terduga (*edge cases*) dan menjamin stabilitas serta ketangguhan (*robustness*) sistem.
3. Optimasi Performa: Berbagai teknik optimasi diterapkan untuk mempercepat waktu respons (*response time*) sistem, termasuk optimalisasi kueri basis data, implementasi mekanisme *caching* untuk data yang sering diakses, dan efisiensi pada algoritma skoring.

3.6.2 *Testing dan Validation*

Proses pengujian sistem dilakukan secara berlapis untuk memastikan kualitas dan keandalan dari berbagai aspek, mulai dari fungsionalitas individual hingga pengalaman pengguna secara keseluruhan.

1. Pengujian Unit (*Unit Testing*) Pengujian ini dilakukan pada level komponen individual atau fungsi tunggal dalam kode, seperti fungsi skoring pada pilar tertentu atau sebuah *endpoint* API. Tujuannya adalah untuk memverifikasi bahwa setiap unit bekerja sesuai dengan spesifikasinya secara terisolasi.
2. Pengujian Integrasi (*Integration Testing*) Pengujian ini berfokus pada verifikasi interaksi dan alur data antar lapisan arsitektur yang berbeda,

misalnya antara *Application Layer* dan *Semantic Layer*. Tujuannya adalah untuk memastikan bahwa semua komponen yang terpisah dapat berkomunikasi dan bekerja sama dengan benar.

3. Pengujian Penerimaan Pengguna (*User Acceptance Testing* - UAT) Ini adalah tahap validasi akhir yang melibatkan pengguna aktual (pemain). Tujuannya adalah untuk memastikan bahwa sistem tidak hanya berfungsi secara teknis, tetapi juga memenuhi kebutuhan pengguna, mudah digunakan (*usability*), dan efektif dalam memberikan rekomendasi game yang relevan.

3.7 Evaluasi dan *Lessons Learned*

Proses pengembangan iteratif ini menghasilkan beberapa pembelajaran penting yang membentuk arsitektur final dari sistem:

1. Iterasi 1: Keterbatasan *Reasoner* Formal dimana pembelajaran utama adalah bahwa *reasoner* OWL DL standar, meskipun kuat untuk validasi logis, tidak optimal untuk tugas rekomendasi yang memerlukan skoring kuantitatif dan fleksibilitas performa.
2. Iterasi 2: Validasi Arsitektur Hibrid untuk memvalidasi bahwa pendekatan hibrida dengan menggunakan ontologi untuk representasi pengetahuan dan Python untuk logika inferensi merupakan solusi yang pragmatis dan efektif, menggabungkan kekuatan semantik dengan fleksibilitas prosedural.
3. Iterasi 3: Keunggulan Pendekatan Multi-Pilar sehingga mengonfirmasi bahwa penggabungan beberapa pilar data (preferensi eksplisit, riwayat pencarian, dan data komunitas) secara signifikan meningkatkan kualitas dan dinamisme rekomendasi, serta lebih baik dalam menangani skenario *cold-start*.
4. Iterasi 4: Pentingnya Optimasi dan Stabilitas dengan seiring meningkatnya kompleksitas fungsional, optimasi performa dan penjaminan stabilitas sistem menjadi krusial untuk memastikan pengalaman pengguna yang baik dan kelayakan implementasi di lingkungan nyata.

BAB 4

PENYELESAIAN PERMASALAHAN

- 4.1 Metodologi Pengujian**
- 4.2 Skenario dan Hasil Pengujian**
- 4.3 Tampilan *Website* Secara Keseluruhan**
- 4.4 Analisis dan Pembahasan Hasil**

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

5.2 Saran

DAFTAR PUSTAKA

[1]

https://www.researchgate.net/publication/286065937_The_Effects_of_Info

rmation_Overload_on_Consumer_Confusion_An_Examination_on_User_Generated_Content.

- [2] <https://onlinelibrary.wiley.com/doi/10.1155/2022/6084363>
- [3] <https://ieeexplore.ieee.org/abstract/document/10911173>
- [4] https://www.researchgate.net/publication/372006805_A_Survey_of_Semantic_Web_Based_Recommender_Systems_for_E-Learning
- [5] C. Larman and V. R. Basili, "Iterative and incremental development: A brief history," *Computer (Long. Beach. Calif.)*, vol. 36, no. 6, pp. 47–56, 2003, doi: 10.1109/MC.2003.1204375.
- [6] C. Uysal, A. Onat, and T. Filik, "Non-Contact Respiratory Rate Estimation in Real-Time with Modified Joint Unscented Kalman Filter," *IEEE Access*, vol. 8, pp. 99445–99457, 2020, doi: 10.1109/ACCESS.2020.2998117.
- [7] I. M. Ibrahim, O. F. Nonyelum, I. R. Saidu, N. D. Academy, N. D. Academy, and N. D. Academy, "I T E R A T I V E A N D I N C R E M E N T A L D E V E L O P M E N T A N A L Y S I S S T U D Y O F V O C A T I O N A L C A R E E R," vol. 11, no. 5, pp. 13–24, 2020, doi: 10.5121/ijsea.2020.11502.
- [8] N. L. Le, M. H. Abel, and P. Gouspillou, "Improving Semantic Similarity Measure Within a Recommender System Based-on RDF Graphs," *Lect. Notes Networks Syst.*, vol. 691 LNNS, pp. 463–474, 2023, doi: 10.1007/978-3-031-33258-6_42.
- [9] L. J. Chew, S. C. Haw, S. Subramaniam, and K. W. Ng, "A Hybrid Ontology-based Recommender System Utilizing Data Enrichment and SVD Approaches," *J. Syst. Manag. Sci.*, vol. 12, no. 5, pp. 139–154, 2022, doi: 10.33168/JSMS.2022.0509.
- [10] A. M. Pereira *et al.*, "Customer models for artificial intelligence-based decision support in fashion online retail supply chains," *Decis. Support Syst.*, vol. 158, 2022, doi: 10.1016/j.dss.2022.113795.

- [11] E. Çano and M. Morisio, “Hybrid recommender systems: A systematic literature review,” *Intell. Data Anal.*, vol. 21, no. 6, pp. 1487–1524, 2017, doi: 10.3233/IDA-163209.
- [12] A. Lorvão Antunes, J. Barateiro, and E. Cardoso, “Strategic Analysis in the Public Sector Using Semantic Web Technologies,” *Digit. Gov. Res. Pract.*, vol. 5, no. 3, 2024, doi: 10.1145/3656587.
- [13] S. Jenny Kalaiarasi and K. Nimala, “Improving E-Commerce Recommendation System with SOBPA: A Semantic Ontology-Based Approach,” *Proc. 2024 IEEE Int. Women Eng. Conf. Electr. Comput. Eng. WIECON-ECE 2024*, no. December 2024, pp. 239–244, 2024, doi: 10.1109/WIECON-ECE64149.2024.10914908.
- [14] I. A. Fadillah and Z. K. A. Baizal, “Ontology-based Food Menu Recommender System for Pregnant Women Using SWRL Rules,” *Sinkron*, vol. 8, no. 3, pp. 1577–1588, 2024, doi: 10.33395/sinkron.v8i3.13722.
- [15] R. Chandra, S. Tiwari, S. Agarwal, and N. Singh, “Semantic web-based diagnosis and treatment of vector-borne diseases using SWRL rules,” *Knowledge-Based Syst.*, vol. 274, 2023, doi: 10.1016/j.knosys.2023.110645.
- [16] N. Aditya, Z. K. A. Baizal, and R. Dharayani, “Healthy Food Recommender System for Obesity Using Ontology and Semantic Web Rule Language,” *Build. Informatics, Technol. Sci.*, vol. 4, no. 4, pp. 1799–1804, 2023, doi: 10.47065/bits.v4i4.3005.
- [17] L. N. Hakim and Z. K. A. Baizal, “Personalized Ontology-based Food Menu Recommender System for Bodybuilders using SWRL Rules,” *J. Inf. Syst. Res.*, vol. 6, no. 1, pp. 49–57, 2024, doi: 10.47065/josh.v6i1.5755.
- [18] <https://arxiv.org/abs/1903.11723>

LAMPIRAN